

设备管理

以本书开头提到的 Hello World 为例，用户首先通过键盘向 shell 进程输入待执行的命令“./hello”。shell 进程收到键盘命令后，通过文件系统从本地硬盘读取“hello”二进制文件作为输入，加载到内存中并创建进程。进程启动执行后，将内存中的“Hello, world”字符串输出到显示器的屏幕上。上述过程中所使用的键盘、硬盘和显示器，是计算机软件（如操作系统和应用程序）感知外部世界以及和用户交互的硬件模块。这些硬件模块通常称为 I/O 设备（Input/Output Device，输入/输出设备），有时也称为外部设备（Peripheral Device，简称外设）。

I/O 设备类型众多且功能迥异，常见的设备包括键盘、鼠标、触摸屏、显示器、摄像头、麦克风、音箱、网卡、硬盘、串口、时钟等，其特征的多样性和差异性如表 13.1 所示。I/O 设备的多样性为操作系统的管理带来了巨大挑战。操作系统往往会引入外部开发者来协助开发与设备交互所使用的代码，即设备驱动（Device Driver，简称驱动）。在操作系统上编写新的设备驱动并提供相关的设备管理功能通常需要较大的工作量，如果缺乏合适的编程框架，则会阻碍操作系统在新平台和新设备上移植和适配的进度。因此现代操作系统通常会提供一套层次化的设备管理框架，沉淀设备管理的共性代码，以减少外部开发者的工作量。自底向上地，本书将操作系统设备管理相关的软件栈分为三层，如图 13.1 中的彩色部分所示。

表 13.1 I/O 设备的多样性

特 征	属 性	例 子
传输速度	高速	网卡、SSD
	低速	鼠标、键盘、串口
访问模式	顺序	时钟、串口
	随机	各类存储设备
读写粒度	字节	鼠标、键盘、串口
	块 / 页 / 帧	硬盘、显卡、网卡
I/O 类型	输入	鼠标、键盘、摄像头、扫描仪
	输出	麦克风、显示器、打印机
	输入 / 输出	触摸屏、硬盘、网卡




图 13.1 操作系统设备管理软件栈的层次划分

操作系统设备管理软件栈各层的功能如下。

- 设备驱动层。对于每种设备，硬件制造商都设计了与之对应的一套操作规范。设备驱动是操作设备的代码集合，一般以插件模块的形式存在，可以方便地添加到现有操作系统中。设备驱动和设备本身的能力高度相关，不同设备的驱动复杂度差异很大。操作系统专门设计了驱动模型或驱动框架，用于聚类功能相似的驱动程序。利用操作系统提供的驱动框架，在添加新设备时，外部开发人员可以尽可能地复用已有的相关逻辑，减少开发新驱动的工作量。
- 设备管理的共性功能层。设备驱动是面向具体设备的，不同设备一般有与之对应的不同驱动。而从操作系统的角度来说，不同设备之间有着类似的管理需求。例如，操作系统需要为应用程序尽可能屏蔽不同设备在传输带宽、访问模式、读写粒度等方面的差异，同时向应用程序提供设备管理相关的合适的系统调用接口。该层是操作系统为设备的共同管理需求而沉淀出的统一抽象层。
- 应用 I/O 框架层。应用 I/O 框架层为应用程序提供了自主可定制的 I/O 管理能力，通常以共享库的形式存在，如 C 语言标准库中的 `stdio`。此外，应用程序还可以采取绕过操作系统内核（Kernel-bypass）的方式与 I/O 设备直接交互，如面向高性能网络场景的 DPDK 库^①等。

13.1 硬件设备基础

本节主要知识点

- 设备是如何连接到 CPU 上的？
- 设备向 CPU 提供了什么样的编程接口？
- 常见的设备有哪些共同点和不同点？

① 参见 <https://www.dpdk.org/>。

尽管设备的种类繁多、功能各异，但是设备一般是通过总线互联的方式和 CPU 连接，同时向 CPU 提供统一的硬件编程接口——设备寄存器。本节首先对 CPU 连接设备 and 操作设备的方式进行介绍，然后介绍一些常见的设备类型以及它们的不同性质，这有助于理解操作系统中的设备管理。

13.1.1 总线互联

为了将计算机系统中的 CPU、内存和设备连接起来，计算机设计师引入总线（Bus）作为各组件之间的通信线路。CPU 通过总线对内存数据进行读写，同样通过总线对设备进行访问。根据连接对象，总线可分为系统总线（System Bus）和外设总线（Peripheral Bus）：系统总线连接 CPU 和内存以及高性能的设备，外设总线则与网卡、显卡或者其他外设总线（如常见的 PCI 总线、USB 总线）相连接。

总线架构伴随着计算机架构的发展而不断演进，不同厂商生产的计算机内部的总线物理拓扑结构不尽相同。不可否认的是，总线的出现为将新的硬件设备加入现有计算机系统中提供了便利：不同硬件厂商可以设计和生产功能各异的硬件设备，但只要符合同一套总线标准，就可以被当前计算机系统识别并能够进行交互，在硬件层面上保证了系统整体的可扩展性和可维护性。

下面介绍两种常见的总线。

- AMBA 总线。由于 ARM 生态十分庞大，不少厂商都可以基于 ARM 定制芯片并选择不同的设备整合成片上系统（System-on-a-Chip, SoC）[Ⓐ]，于是 ARM 提出了统一的总线标准——高级微控制器总线架构（Advanced Micro-controller Bus Architecture, AMBA）标准，用于整合 ARM SoC 的芯片设计生态。图 13.2 展示了 AMBA 总线标准的大致结构，不同平台上的 AMBA 总线互联有所不同。



图 13.2 ARM 片上系统基于 AMBA 的总线拓扑结构（示例）

- PCI/PCIe 总线。PCI 是外设总线中一种常见的总线标准，全称为设备组件互连（Peripheral Component Interconnect, PCI）标准。为了方便识别总线上的多个设

Ⓐ 片上系统：将处理器、存储器和一些硬件设备组件直接集成在单块芯片上。

备，PCI 总线标准设计了基于总线号（Bus Number）、设备号（Device Number）、功能号（Function Number）的组合（简称 B/D/F）作为设备索引。PCIe（PCI Express）总线相比 PCI 总线而言数据传输带宽更高，但保持了和 PCI 标准的兼容性，即同样使用 B/D/F 索引设备。

13.1.2 设备的硬件接口

如图 13.3 所示，设备通常可以分为外部接口和内部组成。




图 13.3 设备的外部接口与内部组成

I/O 设备的设计者和制造商约定俗成地将设备的外部接口设计为一组寄存器，称为设备寄存器，作为设备操作的统一编程接口。运行在 CPU 上的驱动程序通过读写设备寄存器对设备进行配置和交互。

根据用途，设备寄存器通常可分为如下几种类型：

- 控制寄存器：用于向设备发送特定的控制指令，如使能中断、调整工作模式等。
- 数据寄存器：用于 CPU 和设备之间的数据交换，包括输入和输出。
- 地址寄存器：用于配置控制命令或数据读写所使用的具体地址。
- 状态寄存器：用于查询当前设备的工作状态，状态可能包括空闲、就绪、忙碌、完成、出错等。当设备处于忙碌状态时，将暂时无法响应 CPU 发出的操作请求。通过获取设备的出错状态，驱动程序可以做出合适的错误处理，比如数据格式错误或超时无响应等。

除了外部接口外，设备内部通常配有专用的微控制器，以完成设备相关的特定逻辑或功能。设备还可能配置一定大小的内部存储区域，用于存放当前的设备状态。尽管设备的内部组成对外不可见，但驱动程序可以通过访问设备寄存器的方式，配置设备的微控制器并间接读取设备的内部存储数据。

13.1.3 几种常见的设备

实时时钟

实时时钟（Real-Time Clock，RTC）是主板上由微型电池供电的时钟芯片，为操作系统提供查询时间的服务。实时时钟一般以秒为粒度进行更新，记录了 1970 年 1 月 1 日到如今所经历的秒数。如图 13.4 所示，操作系统通过实时时钟的寄存器可以获取当前的

年、月、日乃至秒级的时间。




图 13.4 实时时钟和定时器的主要结构

在启动之初，操作系统通过实时时钟获取当前时间。在连接互联网时，操作系统可以对实时时钟进行校准。在系统断电后，实时时钟依然能通过微型电池工作很长时间，进而在系统未接入互联网时提供可靠的时间 / 日期参考，如文件系统的时间戳服务等。实时时钟的警报计数器则能提供秒级的定时警报功能，当时间计数器和警报计数器的值相等时，实时时钟将向 CPU 发送一个时钟信号。

定时器

定时器（Timer）提供了比实时时钟更高精度的时钟机制，即相对高频的周期性时钟脉冲。定时器可以通过晶体振荡器（Oscillator）的分频方式实现，也可以通过衰减测量器（Decrementer）的递减方式实现。图 13.4 展示了基于分频方式的定时器。操作系统可以通过设备寄存器配置定时器的计数器，决定以何种频率向 CPU 发送时钟信号，从而实现定时的效果。定时器对操作系统的抢占式调度而言至关重要。

串口

串口的全称是通用异步收发传输器（Universal Asynchronous Receiver/- Transmitter, UART），是用于实现不同计算机之间点对点通信的设备。串口设备的主要特点是逐字节地发送和接收信息。串口通信协议定义了如何将若干比特（Bit）编码为字节（Byte）：每个字节以特定的开始位（Start Bit）开头，以特定的停止位（Stop Bit）收尾，并使用奇偶校验位（Parity Bit）检验字节传输的正确性。

图 13.5 展示了串口的基本内部结构，主要包含串口设备寄存器、收发数据的 FIFO 队列、波特率发生器和对外引脚。FIFO 队列作为串口内部存储，可以在突发大量信息传输（Burstiness）的情况下缓存一部分字节流。波特率发生器则用于决定串口收发信息的工作频率。串口设备具有多个引脚，最核心的是发送引脚 Tx 和接收引脚 Rx。通信时收发双方需要将彼此的 Tx 与 Rx 相互连接，才能完成点对点通信需求。

串口编程时，需要软件通过设备寄存器显式配置波特率，即初始化串口的数据传输速度。收发双方需要使用相同的波特率才能成功通信。由于串口具有协议简单、易于配置的优点，因此常用于系统开发和调试阶段的信息收集。




图 13.5 串口 UART 控制器的主要结构 (FIFO 缓存收发的字符)

网卡

网卡是计算机用于连接网络并与其他计算机进行通信的设备。网卡有多种别称，如网络接口控制器 (Network Interface Controller, NIC) 或网络适配器 (Network Adapter)。网卡通过总线的方式和 CPU 互联，比如基于 PCI 总线的网卡或者基于 USB 总线的网卡。

图 13.6 展示了网卡的主要结构。网卡的控制单元通常被分为以太网媒体接入控制器 (Media Access Control, MAC) 和物理接口收发器 (PHY)。MAC 负责控制网络包的收发，管理相关的发送队列和接收队列。PHY 负责电气信号的编解码和传输，通过物理接口与网线连接。PHY 通常配有 LED 显示，用于展示网卡的工作状态，当网线接入网卡并开始传输网络包时，LED 灯会以一定频率闪烁。此外，网卡内置了一块闪存存储区域。网卡设备在生产时会被设备厂商分配一个 48 位的网卡地址，即 MAC 地址，记录在网卡的闪存中。软件可以通过设备寄存器读取存储在闪存中的 MAC 地址。




图 13.6 网卡的主要结构 (Rx、Tx 队列存储网络包的描述符)

根据传输介质的不同，网卡被分为有线网卡和无线网卡。根据网络传输的带宽，网卡被分为十兆网卡、百兆网卡、千兆网卡等。其中千兆网卡已经是现代大多数桌面电脑的标配。网卡驱动可以根据需要使用设备寄存器切换不同的网络传输带宽。

为了实现 CPU 和网卡设备的高效数据交换，网卡上配备了用于发送和接收网络数据包的专用队列——Tx 队列和 Rx 队列。和串口收发数据的 FIFO 队列不同，网卡队列并不实际存放数据包。实际数据存放在物理内存中，而队列则由一组指向物理内存数据的描述符 (Descriptor) 组成。如代码片段 13.1 所示，描述符内包含数据包在物理内存中的

地址和长度，以及网卡对该描述符的处理状态和错误码。不同网卡设备厂商的描述符设计大同小异。操作系统需要在检测到网卡设备后，为 Tx 和 Rx 队列的每个描述符初始化对应的内存缓冲区，还需要将缓冲区的地址和长度通过网卡设备寄存器的方式填写到描述符中，这样才能启用网卡数据包的收发。

代码片段 13.1 网卡收发队列的描述符的数据结构（不同网卡间存在差异）

```
1 struct descriptor
2 {
3     uint32_t addr;           // 描述符对应的网络帧地址
4     uint16_t length;         // 描述符对应的网络帧长度
5     uint8_t status;          // 描述符的处理状态
6     uint8_t error;           // 描述符对应的错误码
7 };
```

机械硬盘

机械硬盘（Hard Disk Drive，HDD）是一种常用的存储设备。图 13.7 展示了机械硬盘的主体结构，主要包括磁柱、磁碟、机械臂和磁头。机械硬盘的结构类似于黑胶唱片，两者都是通过一个“针头”访问不断旋转的圆盘上的数据。和黑胶唱片不同的是，机械硬盘中的磁碟与机械臂是一体的，用户无法自行更换磁碟或机械臂。黑胶唱片使用物理凹槽来记录信息，机械硬盘则是在磁碟上以磁效应记录信息。机械硬盘通常配有多个磁碟、机械臂与磁头，每个磁碟的两个表面都能存储数据。每个机械硬盘的磁碟表面被划分成多个同心圆环，称为磁道。机械臂需要通过移动（通常是围绕臂柱摆动，以调整磁头距离磁柱的距离）来访问不同位置的数据。机械硬盘的旋转非常高速，常见转速为每分钟 5 400 转或 7 200 转。




图 13.7 机械硬盘的主体结构

机械硬盘的地址映射。机械硬盘的信息保存在以磁柱为中心的磁道上，磁道按照角度又进一步划分成不同的扇形区域，简称扇区。扇区是机械硬盘最小的访问单元。早期的机械硬盘每次访问的数据量为一个扇区（通常为 512 字节）。早期的操作系统使用机械硬盘中的存储空间时，需要首先指定要访问的扇区地址。现代机械硬盘普遍向操作系统呈现出连续的地址空间，操作系统仅需要使用逻辑块地址（Logical Block Address，LBA）就可以对机械硬盘中的特定扇区（即物理块地址，Physical Block Address，PBA）进行访问。

闪存

闪存存储（Flash Storage）是一种不同于机械硬盘的存储介质，使用电介质的形式，不再需要耗时的机械操作，因此在读写速度上明显优于机械硬盘。图 13.8 展示了闪存存储的主要结构。在闪存存储介质中，页（Page）如同机械硬盘中的扇区，是用于读取和写入的闪存介质的最小单元。页大小通常为 4KB 到 512KB 不等。除了数据外，每个页

还会保存一些额外的元数据，这些元数据用于辅助存储介质的管理。多个页组成一个块 (Block)，块大小多在 2MB 左右。多个块组成一个面 (Plane)。一些存储命令可以同时操作两个面中的数据。面进而组成带 (Die)，也被称为芯片 (Chip)。通常一个闪存存储介质会包含几个带，这些带共享一组数据总线和一些常用的信号控制线，但也各自拥有如使能 (Enable)、就绪 (Ready) 和忙碌 (Busy) 等信号。除了访问性能和存储结构之外，闪存存储的访问特性也与机械硬盘有较大不同。下面介绍闪存存储的主要特性。




图 13.8 闪存存储的主要结构

写入与擦除循环。闪存存储的主要特点是已经写入的数据不能直接以覆盖的形式修改。如果想要修改，需要先执行擦除操作。在擦除时，闪存存储以块粒度进行擦除。例如，若需要修改闪存上的 1 个字节，需要将该字节所在闪存块——假设是 2MB——保存的数据先读入内存，然后将 2MB 的闪存块全部擦除，再把修改后的数据从内存写回闪存块。这里的写放大倍数高达 2 000 000 倍 (2MB/1 字节)。

磨损和耐久度。随着使用次数的增加，闪存存储介质的存储能力会逐渐下降，即产生磨损。闪存中的存储单元在进行大量写入和擦除后，会发生写穿 (Wear-out) 问题，无法继续用于准确地保存和读取数据。设备控制器中经常使用磨损均衡 (Wear Leveling) 技术，尽可能地让写入操作平均分摊在不同的存储单元中，使所有的存储单元尽可能同时老化，从而避免由于写穿的存储单元过多导致整个闪存无法使用。

固态硬盘

固态硬盘 (Solid State Drive, SSD) 由多块闪存 (Flash Package) 和相关控制器组成。图 13.9 展示了固态硬盘的结构。固态硬盘的控制器包括主机接口、闪存控制器、内存缓冲区等单元。主机接口负责与主机进行通信，通常是 NVMe、SATA、PCIe 等接口协议中的一种。对固态硬盘的管理和数据请求均需通过主机接口解码后交由闪存控制器进一步处理。请求完成后，再由主机接口单元按照对应通信协议进行编码，发还给主机。为了降低数据从内存中写入固态硬盘的延迟，固态硬盘会内置一块内存缓冲区，用于临时存放要写入闪存的数据。数据从主机传入固态硬盘时，会先临时存储在内存缓冲区中，之后异步地写入闪存介质中。




图 13.9 固态硬盘的结构

垃圾回收。由于无法直接覆盖闪存页中的数据，被修改的数据在闪存存储中会有多个版本。为了回收旧的数据，固态硬盘控制器通常会记录每个页是否有效。当一个块中的所有页都变为无效时，控制器将对这个块进行擦除操作；在擦除操作完成之后，控制器将这个块标记为可用，后续的写入或修改操作可以继续在该块的闪存页中进行。

并行性。固态硬盘没有机械硬盘磁头的机械限制，因此具有更高的并行性。固态硬盘中包含多个闪存存储单元，并提供多个访问通道（Channel）。如在图 13.9 中，有两个通道用于访问四个闪存存储。每个通道可以独立使用，因此固态硬盘可以同时处理多个存储请求。

闪存翻译层。固态硬盘中的存储介质以页为单位进行寻址，每个页有各自的物理地址（Physical Block Address）^①。在固态硬盘中存在两种地址：逻辑地址（LBA）和物理地址（PBA）。逻辑地址用于对固态硬盘外部呈现一个连续的地址空间，而物理地址则为内部闪存存储的实际地址。闪存翻译层（Flash Translation Layer, FTL）用于维护两套地址空间之间的映射。

机械硬盘的寻道和闪存的擦除均是比较慢的操作。机械硬盘的寻道往往出现在关键路径中，因此对性能有关键性的影响。而闪存的擦除却较少出现在关键路径中。通过闪存翻译层，新的数据可以写在已经被擦除的块中，而旧的数据可以被异步擦除。通常只有当缓存中剩余空间较少，同时缺少足量的被擦除但未被使用的块时，才会在关键路径上发生垃圾回收。等待垃圾回收往往会造成固态硬盘的读写性能下降。

13.2 设备发现与交互

本节主要知识点

- 操作系统是如何发现设备的？
- CPU 可以通过哪些方式访问设备寄存器？

① 为了与机械硬盘的称呼保持一致，固态硬盘虽然以页为单位进行寻址，但地址被称为块地址。