

系统虚拟化

20 世纪 50 年代，计算机系统主要以批处理（Batch Processing）的方式完成用户的计算任务。到了 60 年代，多位学者提出分时（Time-sharing）的概念，支持用户以“独占”的方式使用机器，这不仅大大改善了用户体验，也提高了机器的资源利用率。同时期，为了在大型机中支持分时，IBM 公司探索了一种不同的技术——系统虚拟化技术。1968 年，IBM 在大型机 System/360-67 中实现了第一个商用虚拟机监控器（Virtual Machine Monitor, VMM，也称为 Hypervisor）CP/CMS（Control Program/Cambridge Monitor System）。作为第一代虚拟机监控器的代表，CP/CMS 已经具备虚拟机监控器的典型架构。它分成两个部分，CP 是虚拟机监控器，负责创建和运行虚拟机（Virtual Machine, VM），并在其内运行 CMS。

20 世纪 80 年代，个人计算机逐渐流行起来，苹果等公司相继推出个人计算机产品。此时，一些公司发布软件模拟器^①，能够在非 x86 的硬件架构上运行 x86 操作系统。例如，英国的 Insignia Solutions 公司于 1987 年发售名为 SoftPC 的软件模拟器，它可以在 UNIX 工作站上运行 MS-DOS 操作系统。然而，当时个人计算机的运算能力依然难以高效地支撑虚拟机的运行，因此整个 80 年代后期和 90 年代中前期，系统虚拟化技术未出现较大的发展。

20 世纪 90 年代，互联网兴起，大量服务器运行 Web 服务，甚至逐渐出现服务器算力过剩的情况。1997 年，斯坦福大学开发了 Disco 系统^[1]——一个可以在多核主机中运行的虚拟机监控器。此后，Disco 开发者将他们的技术商业化，并于 1998 年创立 VMware 公司，这标志着系统虚拟化技术的复兴。到了 2000 年，互联网泡沫破灭，原先运行 Web 服务的服务器大量闲置。如何提高服务器的资源利用率，成为互联网企业和服务器托管企业重点关注的问题。于是，系统虚拟化技术再次成为研究的热点。

随着云计算的出现和流行，系统虚拟化技术变得越来越重要。基础设施即服务（Infrastructure as a Service, IaaS）是一种重要的云计算模式，用户无须自己维护物理服

① 软件模拟器是一种使用纯软件技术实现的虚拟机监控器。

务器，而是租用云服务商的虚拟机，在虚拟机中部署并运行程序，降低了运维成本。云服务商则通过系统虚拟化技术，大大提高了物理服务器的资源利用率，通过将大量服务器整合租售的方式实现规模效应，提升了经济效益。正因为云计算模式为用户和服务提供商双方都能带来收益，此模式在近 20 年内得到了大规模推广，计算能力也逐渐变得和水、电、煤气一样，成为一种按需购买、价格低廉的商品。在这个过程中，系统虚拟化技术起到了关键的作用。具体来说，系统虚拟化技术带来了以下优势：

- 服务器整合：传统数据中心服务器 CPU 的平均利用率仅为约 20%^[2]，通过在一台物理服务器上整合多个虚拟机，可有效提高资源利用率，降低成本。同时，基于用户“错峰使用”的特性，甚至可以使虚拟机的资源总数超过物理主机的资源，即云计算中的“超售”。
- 虚拟机管理：相比传统服务器，虚拟机管理简化了许多。例如，通过软件接口，可以在短时间内创建数千台虚拟机并安装操作系统环境，也可以直接对虚拟机进行复制、备份、建立快照、销毁等操作。
- 虚拟机热迁移：虚拟机监控器可将正在运行的虚拟机从一台物理服务器迁移到另一台物理服务器，整个过程无须停机或重启。热迁移不但能解决物理服务器维修导致的服务暂停问题，也能更好地实现全局的负载均衡。
- 虚拟机安全自省：虚拟机自省（Virtual Machine Introspection, VMI）技术允许虚拟机监控器从外部检查虚拟机内部状态是否正确，以此判断虚拟机是否遭到入侵，例如被攻击者植入 Rootkit^①。

14.1 系统虚拟化技术概述

本节主要知识点

- ❑ 什么是系统虚拟化技术？
- ❑ 虚拟机监控器与操作系统的区别是什么？
- ❑ 虚拟机监控器的架构有哪些类型？

14.1.1 系统虚拟化及其组成部分

系统虚拟化技术能在一台物理主机上创建多个虚拟机^②。从应用程序的角度来看，虚

① Rootkit 是一种恶意程序，可被攻击者安装在操作系统内核中，它可以隐藏自身以及相关的所有信息，从而避免被检查出来。

② 虚拟机也被称为客户机（Guest Machine），和客户机相对应的物理主机则被称为宿主机（Host Machine）。因此，客户机内运行的操作系统可被称作客户操作系统，宿主机的操作系统为主机操作系统。

拟机和真实的物理主机几乎没有区别。系统虚拟化技术的核心是虚拟机监控器，它一般运行在 CPU 的最高特权级，直接控制硬件，并为上层软件提供虚拟的硬件接口，让这些软件“以为”自己运行在真实的物理主机上。

系统虚拟化技术主要包含三个方面，即 CPU 虚拟化、内存虚拟化和 I/O 虚拟化。

- CPU 虚拟化：为虚拟机提供虚拟处理器（Virtual CPU，vCPU）的抽象并执行其指令的过程。虚拟机监控器直接运行在物理主机上，使用物理 ISA，并向上层虚拟机提供虚拟 ISA。虚拟 ISA 可以与物理主机上的 ISA 相同，也可以完全不同。如果两者相同，虚拟机中的大多数指令可以在物理主机上直接执行，只有少数敏感指令需要特殊对待，因此具有较好的性能。如果两者不同，虚拟机中的每一条指令都必须通过虚拟机监控器进行软件模拟，翻译成对应物理主机上的指令。
- 内存虚拟化：为虚拟机提供虚拟的物理地址空间。在虚拟化环境中，虚拟机监控器负责管理所有物理内存，但又要让客户操作系统“以为”自己依然能管理所有物理内存。为此，虚拟机监控器引入了一层新的地址空间——“客户物理地址”，以与真实的物理地址区分。虚拟机监控器还提供了一种翻译机制，将虚拟机中“假”的物理地址翻译成“真”的物理地址。
- I/O 虚拟化：为虚拟机提供虚拟的 I/O 设备支持。在虚拟化环境中，虚拟机监控器负责管理所有的 I/O 设备，客户操作系统所管理的仅仅是虚拟机监控器提供的虚拟设备，虚拟机监控器需要将对虚拟设备的访问映射成对物理设备的访问。

14.1.2 虚拟机监控器的类型

1974 年，Gerald J. Popek 和 Robert P. Goldberg 提出，高效的系统虚拟化需要满足以下三个条件^[3]：

- 条件 1：虚拟机监控器为虚拟机内的程序提供与该程序的目标执行硬件完全一样的硬件接口。这意味着，所有能在物理主机上运行的程序，都应该能够运行在虚拟机上。
- 条件 2：虚拟机运行时的性能只比无虚拟化的情况下略微差一点。
- 条件 3：虚拟机监控器控制所有物理系统资源，例如 CPU、内存、存储、网络等资源。换句话说，虚拟机不能使用任何不属于它的资源，虚拟机监控器也可以在任何时候回收资源。

Goldberg 将虚拟机监控器分为两种类型，分别是 Type-1 和 Type-2，如图 14.1 所示。Type-1 型虚拟机监控器直接运行在最高特权级，可直接控制物理资源，并负责实现调度和资源管理等功能。可以将 Type-1 虚拟机监控器理解为一种特殊的操作系统，它所管理的“进程”就是虚拟机。Type-1 虚拟机监控器的典型代表是 Xen[Ⓔ]。

[Ⓔ] 参见 <https://xenproject.org/>。




图 14.1 两种虚拟机监控器：Type-1 和 Type-2

Type-2 型虚拟机监控器需要依托一个宿主操作系统，比如 Linux 或 Windows。Type-2 型监控器可以复用宿主操作系统中的调度和资源管理等功能，从而专注于提供虚拟化相关的功能。与 Type-1 不同的是，Type-2 虚拟机监控器更像是宿主操作系统上的一个进程，典型代表是 QEMU。其中，操作系统内核（例如 Linux）负责资源管理，QEMU 负责提供核心的虚拟化功能。

14.2 “下陷 – 模拟” 方法

本节主要知识点

- 什么是“下陷 – 模拟”方法？
- 进程和虚拟机有什么相似点和不同点？
- 如何在多物理 CPU 的主机上运行多个虚拟 CPU？

如何把一台计算机虚拟化成多台计算机，使每台虚拟的计算机都能运行自己的操作系统？我们已经知道，操作系统和应用程序都是软件，由一条条指令组成。无论是进行运算、读写内存还是访问设备，都是由 CPU 通过执行这些指令来完成的。所以虚拟化一台计算机，最重要的是虚拟化 CPU 的接口，将一个物理 CPU 虚拟化成多个虚拟 CPU (vCPU)。我们也已经知道，CPU 的接口分为用户 ISA 和系统 ISA，操作系统通过进程这一抽象，支持多个应用在一个 CPU 上同时运行，即已经实现了用户 ISA 的虚拟化。如此可以推导出一个结论：如果在进程的基础上，再增加对系统 ISA 的虚拟化，就可以实现对整台计算机的虚拟化。换句话说，如果我们能够为进程增加系统 ISA 虚拟化的能力，将其扩展成一种新的“虚拟机进程”，然后将一个操作系统运行在这个虚拟机进程中，保